PUCPR

PONTIFÍCIA UNIVERSIDADE CATÓLICA DO PARANÁ

DATA ANALYTICS / PROJETO BASEADO EM PROBLEMAS

RA1

Ingestão e preparação dos dados

Modelo de documentação da entrega

Projeto: Readmission Rates

Curso e turma: Sistemas de Informação • 6A • 6 período

Professor ou professora: Marina de Lara

Equipe: Bruno Viccenzo Mazetto • Helen Lauren Bonato • Letícia Bastias Fabri

Repositório: https://github.com/HelenLauren/Data-analytics

Entrega: Curitiba • 14/10/2026

Este documento acompanha a implementação no repositório. Registre o caminho dos arquivos, notebooks ou células que comprovam cada etapa. O resultado do RA1 será a base para os próximos RAs.

RA1 / 01

Problema e perguntas analíticas

Defina o contexto do projeto e as perguntas que orientarão a seleção e a preparação dos dados.

Contexto e problema

A área da saúde enfrenta desafios relacionados à readmissão hospitalar, especialmente quando pacientes precisam retornar ao hospital pouco tempo após receber alta. Esses retornos podem aumentar os custos assistenciais, ocupar leitos e recursos hospitalares e indicar possíveis dificuldades no tratamento ou na continuidade do cuidado após a alta.

Este projeto investiga quais fatores demográficos, clínicos e relacionados à utilização dos serviços hospitalares estão associados à readmissão de pacientes com diabetes em até 30 dias após a alta. A análise utiliza registros históricos de atendimentos hospitalares para compreender quais características podem estar relacionadas a esse desfecho e estabelecer uma base para futuras análises preditivas.

O problema central é: quais fatores estão associados à readmissão hospitalar em até 30 dias entre os atendimentos registrados de pacientes com diabetes?

Objetivo e recorte

O objetivo do projeto é preparar e analisar dados históricos de atendimentos hospitalares de pacientes com diabetes, buscando investigar a associação entre características demográficas, condições clínicas, tempo de internação, histórico de hospitalizações anteriores e readmissões em até 30 dias.

O conjunto de dados utilizado abrange atendimentos realizados em 130 hospitais dos Estados Unidos, entre 1999 e 2008. A unidade de análise é o encontro hospitalar, identificado pelo campo **encounter_id.** Portanto, um mesmo paciente pode possuir mais de um registro ao longo do período estudado.

Nesta primeira etapa (RA1), o escopo está limitado à obtenção, ingestão, compreensão, avaliação da qualidade, limpeza e preparação dos dados. A construção de indicadores analíticos, a comparação dos resultados entre grupos e o desenvolvimento de modelos preditivos serão realizados nas etapas posteriores do projeto.

Perguntas analíticas

ID	Pergunta a investigar	Dados necessários
P1	Como o tempo de permanência hospitalar está associado à ocorrência de readmissão em até 30 dias após a alta?	time_in_hospital, readmitted e encounter_id.
P2	Pacientes com maior número de internações anteriores apresentam maior ocorrência de readmissão em até 30 dias?	number_inpatient, readmitted, patient_nbr e encounter_id.
P3	A alteração das medicações durante a internação e a presença de múltiplos diagnósticos estão associadas à readmissão em até 30 dias?	change, colunas de medicação, diag_1, diag_2, diag_3 e readmitted.

Viabilidade inicial

O projeto é viável porque o conjunto de dados Diabetes 130-US Hospitals contém mais de 100 mil registros de encontros clínicos e reúne informações demográficas, histórico de utilização hospitalar, diagnósticos, procedimentos, medicações e situação de readmissão.

A variável **readmitted** registra três categorias: readmissão em menos de 30 dias (<30), readmissão após 30 dias (>30) e ausência de readmissão registrada (NO). Essas categorias permitem identificar o desfecho de interesse e orientar análises posteriores.

Entretanto, a base apresenta limitações de qualidade, incluindo valores ausentes representados pelo caractere “?”, colunas com elevada proporção de dados ausentes e identificadores que precisam ser tratados adequadamente. Além disso, o período histórico dos dados não garante que os padrões observados representem integralmente a realidade hospitalar atual. Essas limitações serão consideradas na preparação dos dados e na interpretação dos resultados futuros.

RA1 / 02

Fontes de dados e ingestão

Documente a origem dos dados e como eles são carregados no ambiente do projeto. Duplique a ficha para cada fonte.

Ficha da fonte

Identificação: F1 • Diabetes 130-US Hospitals for Years 1999–2008 (arquivo principal: diabetic_data.csv).

Origem e acesso: O conjunto de dados tem origem no UCI Machine Learning Repository e foi disponibilizado para obtenção por meio do Kaggle. A versão utilizada no projeto é o dataset Diabetes Hospital Readmission Dataset, de razanihababdellatif.

Kaggle: https://www.kaggle.com/datasets/razanihababdellatif/diabetes-hospital-readmission-dataset

Referência original: UCI Machine Learning Repository — Diabetes 130-US Hospitals for Years 1999–2008.

Data de acesso: 14/10/2026.

Formato e volume: O arquivo principal está no formato CSV e contém 101.766 registros e 50 atributos, conforme confirmado pela execução do notebook. Os registros correspondem a encontros hospitalares, e não necessariamente a pacientes únicos.

Os atributos incluem identificadores de pacientes e atendimentos, características demográficas, tempo de internação, histórico de hospitalizações, diagnósticos, procedimentos, exames laboratoriais, medicações e situação de readmissão. O conjunto também disponibiliza o arquivo auxiliar IDS_mapping.csv, que contém informações de mapeamento relacionadas aos dados.

Cobertura: Os dados abrangem atendimentos hospitalares realizados em 130 hospitais dos Estados Unidos, entre os anos de 1999 e 2008. A população representada é composta por pacientes com diabetes registrados nos encontros clínicos da base.

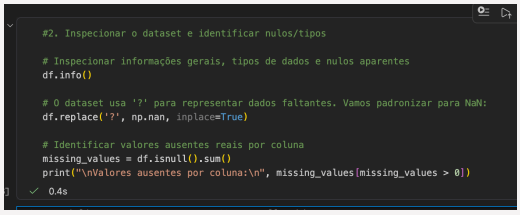
Condições de uso: Os dados são disponibilizados publicamente para fins de pesquisa e estudo. Antes da redistribuição do conjunto de dados, deverão ser verificadas as condições de uso e a licença aplicável à versão utilizada no Kaggle e à fonte original no UCI Machine Learning Repository.

Relação com o problema:

Esta fonte permite investigar as três perguntas analíticas definidas no projeto porque reúne informações sobre duração da internação, histórico de hospitalizações anteriores, diagnósticos, medicações e readmissão. O campo **readmitted** é a principal variável de desfecho, enquanto as

demais variáveis fornecem características que poderão ser relacionadas a esse resultado nas etapas posteriores.

Procedimento de ingestão

Etapa	Procedimento ou parâmetro	Evidência no repositório
1	Obtenção do conjunto de dados por meio da biblioteca kagglehub, utilizando o identificador razanihababdellatif/diabetes-hospital-readmission-dataset.	
2	Carregamento do arquivo diabetic_data.csv por meio de KaggleDatasetAdapter.PANDAS.	
3	Inspeção das dimensões, dos tipos de dados e da presença de valores ausentes.	

Resultado da ingestão

O conjunto de dados foi obtido diretamente do Kaggle por meio da biblioteca KaggleHub, utilizando o identificador razanihababdellatif/diabetes-hospital-readmission-dataset e o arquivo diabetic_data.csv. O carregamento foi realizado com o adaptador Pandas, disponibilizando os dados em um Data Frame para inspeção e preparação.

A execução confirmou que o arquivo contém 101.766 registros e 50 atributos. A visualização inicial apresentou os cinco primeiros registros, confirmando o carregamento dos dados.

Na inspeção inicial, verificou-se que algumas informações ausentes são representadas pelo caractere “?”. Após a substituição desse caractere por **NaN**, foram identificados valores ausentes em nove colunas. Os dados foram preparados para a etapa de avaliação da qualidade

```python
#1.Conectando com a fonte de dados do Kaggle

# pip install kagglehub[pandas-datasets]
import kagglehub
from kagglehub import KaggleDatasetAdapter
import pandas as pd
import numpy as np

file_path = "diabetic_data.csv"

# Carregando versão mais atualizada
df = kagglehub.dataset_load(
  KaggleDatasetAdapter.PANDAS,
  "razanihababdellatif/diabetes-hospital-readmission-dataset",
  file_path,
)

print("Primeiros registros:", df.head())
```

[2] ✓ 4.9s Pytho

```
/Library/Frameworks/Python.framework/Versions/3.12/lib/python3.12/site-packages/tqdm/auto.py:21: TqdmWarn
  from .autonotebook import tqdm as notebook_tqdm
Primeiros registros:    encounter_id  patient_nbr            race  gender      age weight  \
0       2278392      8222157        Caucasian  Female   [0-10)      ?
1        149190     55629189        Caucasian  Female  [10-20)      ?
2         64410     86047875  AfricanAmerican  Female  [20-30)      ?
3        500364     82442376        Caucasian    Male  [30-40)      ?
4         16680     42519267        Caucasian    Male  [40-50)      ?

   admission_type_id  discharge_disposition_id  admission_source_id  \
```

```python
# Inspecionar informações gerais, tipos de dados e nulos aparentes
df.info()

# O dataset usa '?' para representar dados faltantes. Vamos padronizar para NaN:
df.replace('?', np.nan, inplace=True)

# Identificar valores ausentes reais por coluna
missing_values = df.isnull().sum()
print("\nValores ausentes por coluna:\n", missing_values[missing_values > 0])
```

[3] ✓ 0.4s

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 101766 entries, 0 to 101765
Data columns (total 50 columns):
 #   Column                    Non-Null Count   Dtype
---  ------                    --------------   -----
 0   encounter_id              101766 non-null  int64
```

RA1 / 03

Compreensão e qualidade

Descreva o que cada registro representa e apresente evidências das verificações de qualidade relevantes para os dados.

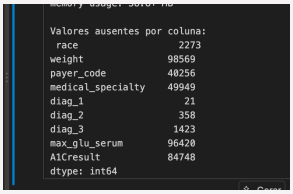
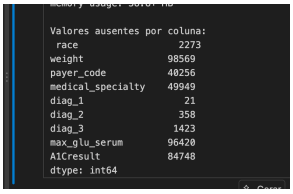
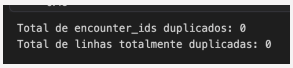
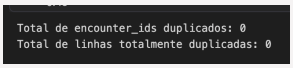
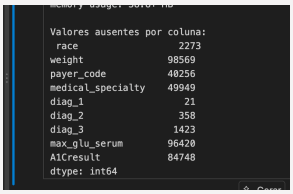
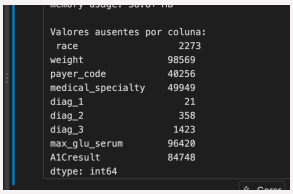
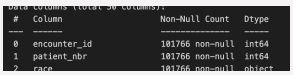
Unidade de observação: Cada linha representa um encontro hospitalar de um paciente com diabetes. Um encontro corresponde a um atendimento identificado pelo campo **encounter_id**. Um mesmo paciente pode aparecer em múltiplas linhas quando possui mais de uma internação durante o período coberto pelo conjunto de dados.

Identificação dos registros: O campo **encounter_id** é utilizado como identificador do encontro hospitalar e deve ser único. O campo **patient_nbr** identifica o paciente e pode aparecer em diferentes registros, pois um paciente pode ter múltiplas internações. Portanto, a repetição de **patient_nbr** não caracteriza, isoladamente, duplicidade de registros.

Dicionário inicial dos dados

Atributo	Significado	Tipo e formato	Unidade ou domínio
encounter_id	Identificador do encontro hospitalar.	Inteiro na base original; convertido para texto na preparação.	Identificador do atendimento.
Patient_nbr	Identificador do paciente.	Inteiro na base original; convertido para texto na preparação.	Identificador do paciente.
Age	Faixa etária do paciente.	Categórico ordinal.	Intervalos como [0-10) e [10-20).
Gender	Gênero registrado do paciente	Categórico	Categorias presentes na base
Time_in_hospital	Duração da internação	Inteiro	Categoria presentes na base
Number_inpatient	Quantidade de internações anteriores	Inteiro	Contagem de internações
Diag_1	Diagnostico principal registrado	Categórico / Código	Códigos de diagnostico
Change	Indicador de alteração de medicação	Categórico	Categorias registradas na base
Readmitted	Situação de readmissão após a alta	Categórico	<30, >30 ou NO

Diagnóstico de qualidade

ID	Verificação e regra	Resultado observado	Evidência
Q1	Valores ausentes em **weight**.	98.569 valores ausentes de 101.766 registros, aproximadamente 96,86%	
Q2	Valores ausentes em **payer_code** e **medical_specialty.**	**payer_code:** 40.256 ausentes (39,56%); **medical_specialty:** 49.949 (49,08%).	
Q3	Duplicidade de **encounter_id.**	Nenhum identificador de atendimento duplicado: 0 ocorrências.	
Q4	Duplicatas de linhas completas.	Nenhuma linha totalmente duplicada: 0 ocorrências.	
Q5	Valores ausentes nas demais variáveis.	**race:** 2.273; diag_1: 21; **diag_2:** 358; **diag_3:** 1.423.	
Q6	Valores ausentes em resultados de exames.	**max_glu_serum:** 96.420; **A1Cresult:** 84.748.	
Q7	Tipos de dados dos identificadores.	**encounter_id** e **patient_nbr** são originalmente int64, embora representem identificadores.	

Impacto dos problemas identificados

Os resultados da inspeção indicam que a coluna **weight** apresenta aproximadamente 96,86% de valores ausentes, tornando sua utilização direta limitada. As colunas **payer_code** e **medical_specialty** também apresentam proporções elevadas de ausências. Além disso, **max_glu_serum** e **A1Cresult** possuem quantidades expressivas de valores ausentes, o que deve ser considerado nas decisões de preparação.

A ausência de valores em **race** e nos diagnósticos também deve ser documentada, embora as proporções sejam menores. Esses valores não devem ser automaticamente tratados como erros: é necessário avaliar sua relevância e o impacto de eventuais exclusões ou imputações.

A verificação de duplicidades não identificou linhas repetidas nem IDs de atendimento duplicados. Portanto, com base nos resultados observados, não foi necessário remover registros por duplicidade nesta etapa. A correção dos tipos dos identificadores continua pertinente, pois eles representam chaves e não medidas quantitativas.

RA1 / 04

Limpeza e preparação

Relacione cada intervenção ao diagnóstico. Justifique tanto os tratamentos realizados quanto as decisões de manter os dados.

Registro das decisões

Decisão e diagnóstico D1 - Padronização dos valores ausentes

Problema e abrangência

O conjunto de dados utiliza o caractere "?" para representar informações ausentes em diferentes colunas. Esse formato impede que o Pandas reconheça automaticamente esses valores como nulos.

Tratamento e justificativa

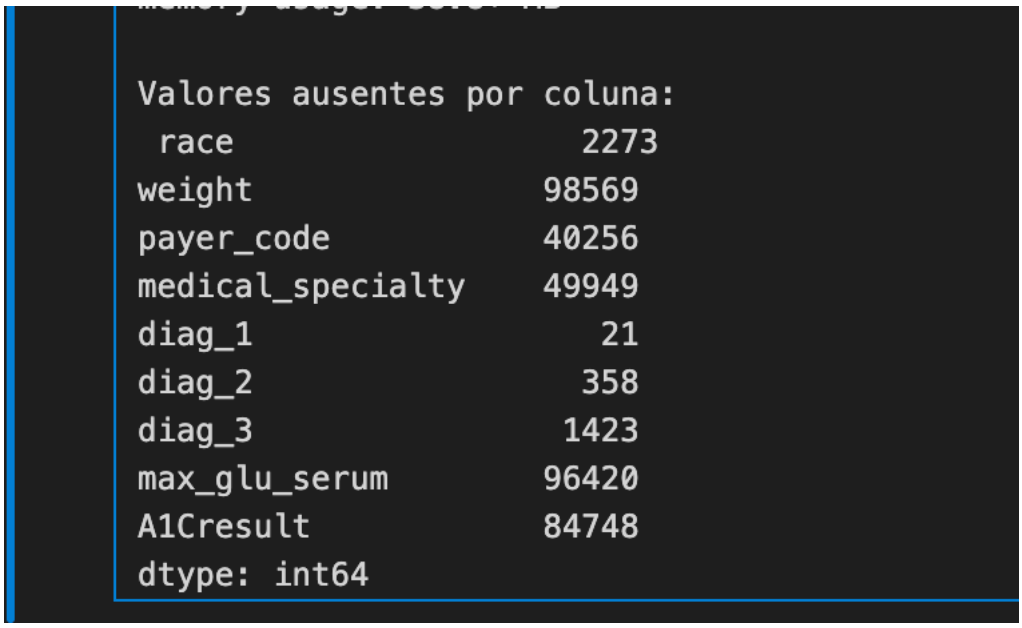
Substituir todas as ocorrências do caractere "?" por **NaN** utilizando o método replace(). Essa padronização permite identificar e contabilizar os valores ausentes de forma consistente. A substituição não elimina registros nem preenche artificialmente informações desconhecidas; apenas padroniza sua representação.

Implementação

```
# O dataset usa '?' para representar dad
df.replace('?', np.nan, inplace=True)
```

Validação após o tratamento

A saída de df.isnull().sum() confirmou valores ausentes em nove colunas: race, weight, payer_code, medical_specialty, diag_1, diag_2, diag_3, max_glu_serum e A1Cresult. A contagem de ausentes permitiu quantificar o problema para cada atributo.



```
Valores ausentes por coluna:
 race                 2273
weight               98569
payer_code           40256
medical_specialty    49949
diag_1                  21
diag_2                 358
diag_3                1423
max_glu_serum        96420
A1Cresult            84748
dtype: int64
```

Decisão e diagnóstico D2 - Remoção de colunas com alta proporção de ausências

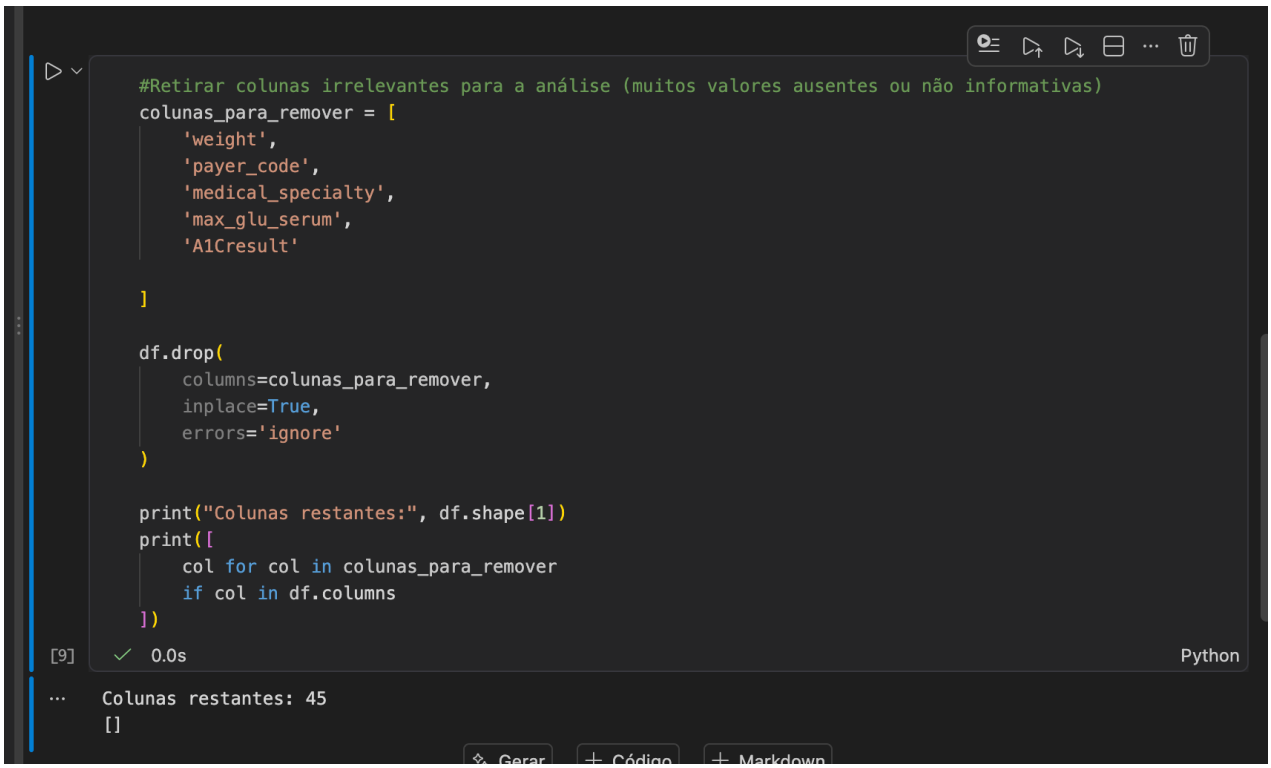
Problema e abrangência

As colunas weight, payer_code e medical_specialty apresentam elevada proporção de valores ausentes. Em particular, weight possui 98.569 valores ausentes em 101.766 registros, aproximadamente 96,86%.

Tratamento e justificativa

A proposta de preparação é remover as três colunas para reduzir a esparsidade e simplificar o conjunto de dados. A decisão deve ser considerada uma escolha metodológica do projeto, pois implica perder as informações que essas variáveis poderiam fornecer.

Implementação



Validação após o tratamento

A saída mostra que, após a exclusão bem-sucedida das colunas, agora existem 45 colunas restantes. Além disso, o print de colunas_para_remover retornou vazio, o que significa que as colunas especificadas para exclusão não existem mais no data frame sendo analisado.

Decisão e diagnóstico D3 - Verificação de duplicidades

Problema e abrangência

Registros completamente duplicados ou identificadores de atendimento repetidos poderiam gerar contagens incorretas de encontros hospitalares. Por isso, foram verificadas tanto a duplicidade da chave **encounter_id** quanto a repetição de linhas completas.

Tratamento e justificativa

A verificação não identificou duplicidades em nenhuma das duas condições. Dessa forma, não houve necessidade de remover registros por duplicidade. A célula de código contém drop_duplicates() como medida de segurança, mas, conforme os resultados obtidos, essa instrução não alterou a quantidade de linhas.

Implementação

```
duplicados_encounter = df['encounter_id'].duplicated().sum()
duplicados_linhas = df.duplicated().sum()

print("IDs de atendimento duplicados:",
      duplicados_encounter)
print("Linhas totalmente duplicadas:",
      duplicados_linhas)

df.drop_duplicates(inplace=True)
```

[11] ✓ 0.3s Python

```
IDs de atendimento duplicados: 0
Linhas totalmente duplicadas: 0
```

Validação após o tratamento

Os resultados anteriores à remoção foram zero duplicatas de **encounter_id** e zero linhas totalmente duplicadas. Como não havia duplicidades, o número de registros permaneceu inalterado por essa intervenção.

Decisão e diagnóstico D4 - Correção dos tipos dos identificadores

Problema e abrangência

Os campos **encounter_id** e **patient_nbr** são identificadores numéricos na base original, mas não representam medidas quantitativas.

Tratamento e justificativa

Converter ambos os campos para texto, preservando sua função de identificação dos encontros e dos pacientes.

Implementação

```
df['encounter_id'] = df['encounter_id'].astype(str)
df['patient_nbr'] = df['patient_nbr'].astype(str)
df.info()
```

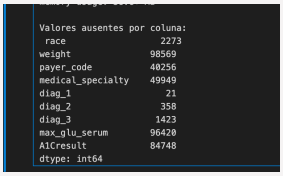
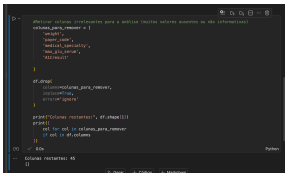
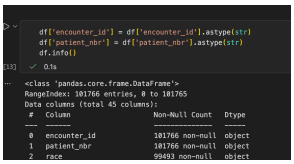
[13] ✓ 0.1s

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 101766 entries, 0 to 101765
Data columns (total 45 columns):
 #   Column                    Non-Null Count   Dtype
---  ------                    --------------   -----
 0   encounter_id              101766 non-null  object
 1   patient_nbr               101766 non-null  object
 2   race                      99493 non-null   object
```

Validação após o tratamento

Os campos de **encounter_id** e **patient_br** agora apresentam Dtype = object.

Resumo das intervenções

Decisão	Ação executada	Impacto nos dados	Evidência
D1	Substituir “?” por NaN.	Padroniza as ausências sem remover linhas.	
D2	Remover weight, payer_code, medical_specialty, max_glu_serum e A1Cresult	Reduz cinco atributos após a execução da limpeza.	
D3	Verificar e remover duplicatas, se existentes.	Nenhuma linha foi removida por duplicidade, pois o resultado inicial foi zero.	
D4	Converter os identificadores para texto.	Altera os tipos de dois atributos, sem reduzir linhas.	

RA1 / 05

Conjunto de dados resultante

Identifique a saída do RA1 e demonstre sua consistência para uso nas próximas etapas.

Arquivo ou conjunto final: diabetic_ data _ clean.csv • data/processed/diabetic_ data_ clean.csv • csv

Unidade de observação final: Uma linha representa um atendimento hospitalar individual (encounter_id) de um paciente diagnosticado com diabetes, admitido em um dos 130 hospitais monitorados nos Estados Unidos entre 1999 e 2008. Um mesmo paciente (patient_nbr) pode possuir múltiplos atendimentos ao longo do período histórico (a base contempla 101.766 atendimentos distribuídos entre 71.518 pacientes únicos).

Dicionário atualizado: Documentado no README.md, seções 2 e 5. O conjunto final é composto por 48 atributos

Comparação antes e depois

Medida	Após ingestão	Após preparação	Explicação da diferença
Registros	101.766	101.766	Sem alteração (0 descartes). A verificação comprovou que não havia linhas duplicadas (df.duplicated().sum() == 0) e que os IDs de atendimento são estritamente únicos. Todos os registros clínicos foram preservados integralmente.
Atributos	50	48	Redução líquida de 2 colunas. Foram descartadas 3 colunas de alta esparsidade e inviabilidade analítica (weight com 96,86% nulos, medical_specialty com 49,08% nulos e payer_code com 39,56% nulos) e foi adicionada 1 coluna derivada de desfecho (readmitido_30_dias). Cálculo: $50 - 3 + 1 = 48$.
Duplicidade de chave primaria (encounter_id)	0 (0,0% de 101.766)	0 (0,0% de 101.766)	Verificado via df['encounter_id'].duplicated().sum() e garantido pela asserção assert df['encounter_id'].is_unique. Integridade de chave assegurada.
Linhas inteiramente duplicadas	0 (0,0% de 101.766)	0 (0,0% de 101.766)	Verificado por df.duplicated().sum() e execução preventiva de df.drop_duplicates(inplace=True).
Valores ausentes mascarados ('?')	192.849 células com '?' (em 7 variaveis)	0 célular com '?' 0 (0,0% de 101.766)	Conversão de todas as ocorrências de '?' para valores nulos padrão (np.nan). Validado com a asserção assert not df.eq('?').any().any().
Registros inválidos em gender	3 registros (0,0029% de 101.766)	0 registros inválidos	Padronização das 3 ocorrências para a categoria explícita 'Não informado', evitando exclusão arbitrária de registros.

Medida	Após ingestão	Após preparação	Explicação da diferença
Tipagem semantica dos identificadores	Int64 (numerico)	Object/string	As colunas encounter_id e patient_nbr foram convertidas para string para impedir cálculos matemáticos espúrios e refletir sua natureza de chaves de identificação.
Variável alvo binária (readmitido_30 _dias)	Inexistente (apenas readmitted categorica com 3 classes)	100% preenchida(0 nulos): 11.357 positivos (11,16%) e 90.409 negativos (88,84%) (denominador: 101.766)	Mapeamento da pergunta central do projeto: 1 para readmissão em menos de 30 dias (<30) e 0 para readmissão após 30 dias (>30) ou ausência de retorno (NO).

Verificações finais

Foram implementadas verificações no script e no notebook HealthData.ipynb, especificamente na célula 6, para validar a qualidade e a integridade da base de dados. O teste de unicidade confirmou que a coluna encounter_id não possui identificadores duplicados, enquanto a verificação de duplicidades gerais comprovou a ausência de registros repetidos. Também foi validada a integridade dos identificadores de atendimento e paciente, por meio da confirmação de que as colunas encounter_id e patient_nbr não apresentam valores nulos.

Além disso, foi realizada uma verificação de ausências ocultas para garantir que nenhum valor textual '?' permanecesse na base após sua conversão para np.nan. A variável alvo readmitido_30_dias foi validada quanto ao domínio estritamente binário, contendo apenas os valores 0 e 1, com tipo int64 e sem valores nulos. Também foi confirmada a exclusão dos atributos weight, payer_code e medical_specialty, considerados inadequados para o conjunto de dados preparado.

A auditoria da variável gender identificou 54.708 registros classificados como Female (53,76%), 47.055 como Male (46,24%) e apenas 3 registros não informados (0,003%), permitindo verificar a distribuição das categorias e identificar possíveis ambiguidades. Quanto aos valores nulos remanescentes, foram identificados apenas quatro atributos com ausências legítimas: race, com 2.273 nulos (2,23%); diag_3, com 1.423 (1,40%); diag_2, com 358 (0,35%); e diag_1, com 21 (0,02%), considerando o total de 101.766 registros. Os outros 44 atributos não apresentam valores nulos.

Por fim, foi configurada a leitura dos dados com keep_default_na=False para preservar a distinção entre dados ausentes e exames não realizados. Dessa forma, o valor textual 'None' nas variáveis max_glu_serum e A1Cresult é mantido como uma indicação de que o exame não foi solicitado durante o atendimento, evitando sua interpretação incorreta como um dado corrompido ou ausente.

Limitações e pendências

Foram identificadas limitações que devem ser consideradas no desenvolvimento dos modelos preditivos, incluindo o desbalanceamento das classes, com apenas 11,16% de readmissões precoces, e a existência de múltiplos atendimentos por paciente, que exige validação agrupada para evitar vazamento de dados (data leakage). Os valores nulos remanescentes em atributos clínicos precisarão de estratégias de imputação, enquanto os códigos ICD-9 deverão ser agrupados em categorias clínicas para reduzir a dimensionalidade e o risco de sobreajuste. A exclusão de medical_specialty e payer_code, devido à elevada proporção de valores

ausentes, representa uma possível perda de informações relevantes. Por fim, a variável age, registrada em faixas etárias, limita a precisão da análise, exigindo codificação adequada durante a preparação dos dados.

RA1 / 06

Organização e reprodutibilidade

Explique como outra pessoa pode obter os dados e executar o fluxo completo do RA1.

Repositório e versão https://github.com/HelenLauren/Data-analytics

Ambiente: Linguagem: Python 3.

Ambiente de execução: Jupyter Notebook ou Google Colab, conforme a versão do notebook disponibilizada no repositório.

Bibliotecas principais: pandas, numpy e kagglehub.

A biblioteca **pandas** é utilizada para leitura, inspeção e manipulação dos dados; **numpy**, para representar valores ausentes; e **kagglehub**, para obter o conjunto de dados do Kaggle.

Localização dos artefatos

Artefato	Caminho ou forma de obtenção
Dados brutos	Download pelo KaggleHub; arquivo principal diabetic_data.csv.
Código de ingestão e preparação	Notebook. ipynb disponibilizado no repositório
Dados preparados	data/processed/diabetic_data_prepared.csv, após sua geração.
Documentação e dependências	README.md, documento RA1 e arquivo requirements.txt

Passos para reprodução

Ordem	Instrução executável	Resultado esperado
1	Instalar Python e as bibliotecas utilizadas no notebook.	Ambiente configurado para executar o projeto.
2	Clonar o repositório e obter os dados pelo KaggleHub.	Arquivo diabetic_data.csv disponível no ambiente.
3	Abrir o notebook e executar as células na ordem apresentada.	Ingestão, diagnóstico de qualidade e preparação executados sem erros.
4	Executar as verificações finais e salvar o conjunto preparado.	Validações registradas e arquivo CSV gerado no caminho documentado.

Verificação da reprodução

20/10/2026, Helen Lauren Bonato, Sistema Operacional: Windows 10/11 (64-bit), Ambiente / IDE: Jupyter Notebook / VS Code, Interpretador Python: Python 3.10.11. Bibliotecas principais e versões: pandas: 2.3.3, numpy: 2.2.6, kagglehub: 1.0.2, pyspark: 4.2.0 (com Java OpenJDK 21 / JAVA_HOME)

O arquivo .csv gerado a partir do passo a passo acima está no repositório do github, commitado!

RA1 / 07

Referências e anexos

Reúna as fontes utilizadas e os materiais complementares que ajudam a verificar a entrega.

Referências

KAGGLE. Diabetes Hospital Readmission Dataset. Disponível em: https://www.kaggle.com/datasets/razanihababdellatif/diabetes-hospital-readmission-dataset. Acesso em: 14 out. 2026.

UCI MACHINE LEARNING REPOSITORY. Diabetes 130-US Hospitals for Years 1999–2008. Disponível em: https://archive.ics.uci.edu/dataset/296/diabetes+130-us-hospitals+for-years-1999-2008. Acesso em: 14 out. 2026.

KAGGLEHUB. KaggleHub Documentation. Disponível em: https://github.com/Kaggle/kagglehub. Acesso em: 14 out. 2026.

Conferência da entrega

☐ Problema, recorte e perguntas analíticas estão definidos.

☐ Fontes e procedimentos de ingestão estão documentados.

☐ A qualidade foi avaliada com evidências verificáveis.

☐ As decisões de limpeza estão justificadas e validadas.

☐ O conjunto de dados preparado está identificado.

☐ O repositório contém instruções suficientes para reprodução.

☐ Os campos-modelo foram preenchidos e os exemplos revisados.